

# ICA aplicado a datos de EEG y fMRI

Ingo R. Keck<sup>1</sup>

<sup>1</sup>Departamento de Biofísica  
Universidad de Regensburg  
Alemania

CIIT 10/2007

- ▶ EEG y fMRI
- ▶ Análisis de Componentes Independientes (ICA)
- ▶ ICA aplicado a datos de EEG
- ▶ ICA aplicado a datos de fMRI
- ▶ Clustering con ICA incompleto
- ▶ ICA incompleto paralelo
- ▶ Conclusiones y Perspectivas

- ▶ EEG y fMRI
- ▶ **Análisis de Componentes Independientes (ICA)**
- ▶ ICA aplicado a datos de EEG
- ▶ ICA aplicado a datos de fMRI
- ▶ Clustering con ICA incompleto
- ▶ ICA incompleto paralelo
- ▶ Conclusiones y Perspectivas

- ▶ EEG y fMRI
- ▶ Análisis de Componentes Independientes (ICA)
- ▶ ICA aplicado a datos de EEG
- ▶ ICA aplicado a datos de fMRI
- ▶ Clustering con ICA incompleto
- ▶ ICA incompleto paralelo
- ▶ Conclusiones y Perspectivas

- ▶ EEG y fMRI
- ▶ Análisis de Componentes Independientes (ICA)
- ▶ ICA aplicado a datos de EEG
- ▶ ICA aplicado a datos de fMRI
- ▶ Clustering con ICA incompleto
- ▶ ICA incompleto paralelo
- ▶ Conclusiones y Perspectivas



- ▶ EEG y fMRI
- ▶ Análisis de Componentes Independientes (ICA)
- ▶ ICA aplicado a datos de EEG
- ▶ ICA aplicado a datos de fMRI
- ▶ Clustering con ICA incompleto
- ▶ ICA incompleto paralelo
- ▶ Conclusiones y Perspectivas

- ▶ EEG y fMRI
- ▶ Análisis de Componentes Independientes (ICA)
- ▶ ICA aplicado a datos de EEG
- ▶ ICA aplicado a datos de fMRI
- ▶ Clustering con ICA incompleto
- ▶ ICA incompleto paralelo
- ▶ Conclusiones y Perspectivas

- ▶ EEG y fMRI
- ▶ Análisis de Componentes Independientes (ICA)
- ▶ ICA aplicado a datos de EEG
- ▶ ICA aplicado a datos de fMRI
- ▶ Clustering con ICA incompleto
- ▶ ICA incompleto paralelo
- ▶ Conclusiones y Perspectivas



MÉTODO	DEFINICIÓN		INVASIVO	PRECIO
	TEMPORAL	ESPACIAL		
MEG	1 ms	5 mm	no	\$\$\$\$
EEG	1 ms	10–15 mm	no	\$
fMRI	3–5 s	1.0–1.5 mm	no	\$\$\$
PET	45 s	4 mm	sí	\$\$



- ▶ Primera publicación por Berger (1929)
- ▶ Neuronas como antenas
- ▶ Muy barato; deficiencia: ms, mm;

# functional Magnetic Resonance Imaging (fMRI)




- ▶ Primera publicación por Ogawa (1990) y Kwong (1992)
- ▶ Basado en resonancia magnética (MRI)
- ▶ Mide: características magnéticas
- ▶ Marcador del flujo de la sangre: desoxihemoglobina (BOLD)


# Blood Oxygenation Level Dependency (BOLD)

Objetivo: Investigación de la actividad cerebral

- ▶ actividad aumentada en una región del cerebro  
→ flujo de la sangre aumentado en dicha región




no activación



activación


# Función de Respuesta de la Hemoglobina



Problemas:

- ▶ diferentes personas tienen diferentes funciones de respuesta
- ▶ depende de la posición dentro del cerebro
- ▶ depende de la historia dentro del experimento

# Forma de toma



- ▶ cada medida resulta en una imagen planar
- ▶ tiempo entre imagenes: 10–100ms

## Análisis clásico de fMRI:

- ▶ General linear model (GLM)

evolución temporal de un voxel:  $\vec{x} = (x(t_1), \dots, x(t_n))^T$

$$\text{GLM: } \vec{x} = \mathbf{F}\vec{b} + \vec{e}$$

$\vec{b}$ : coeficientes de regresión,  $\mathbf{F}$ : funciones del filtro,  $\vec{e}$ : errores de la distribución gaussiana (GLM)

- ▶ **desventaja:** Hay que conocer la evolución temporal de la actividad para el análisis

## Análisis clásico de fMRI:

- ▶ General linear model (GLM)

evolución temporal de un voxel:  $\vec{x} = (x(t_1), \dots, x(t_n))^T$


$$\text{GLM: } \vec{x} = \mathbf{F}\vec{b} + \vec{e}$$

$\vec{b}$ : coeficientes de regresión,  $\mathbf{F}$ : funciones del filtro,  $\vec{e}$ : errores de la distribución gaussiana (GLM)

- ▶ **desventaja**: Hay que conocer la evolución temporal de la actividad para el análisis



# Separación ciega de fuentes (BSS)



- ▶ Se conoce: Mezcla de señales  $\vec{x}(t)$
- ▶ Se busca: Las fuentes originales  $\vec{s}(t)$
- ▶ No hay una única solución  $\rightarrow$  se necesita más información

# Análisis de Componentes Independientes (ICA)

ICA usa las siguientes hipótesis para BSS:

- ▶ las fuentes  $\vec{s}(t)$  son estadísticamente independientes entre sí:

$$p(s_i(t), s_j(t)) = p(s_i(t))p(s_j(t))$$

- ▶ el tipo de la mezcla se conoce, por ejemplo lineal:

$$\vec{x}(t) = \mathbf{A}\vec{s}(t)$$

- ▶ máximo una fuente puede ser Gaussiana

Buena aplicación: Búsqueda de señales en el cerebro.

ICA temporal:

$$\vec{x}(t) = \mathbf{A}\vec{s}(t)$$


- ▶ Las mezclas  $\vec{x}(t)$  son las señales de los sensores
- ▶ Las fuentes  $\vec{s}(t)$  son las señales del cerebro
- ▶ **ventaja:** sin modelo, no hay que conocer la función de actividad para el análisis

ICA temporal:

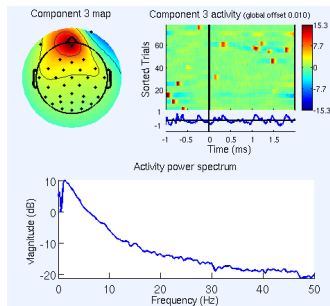
$$\vec{x}(t) = \mathbf{A}\vec{s}(t)$$

- ▶ Las mezclas  $\vec{x}(t)$  son las señales de los sensores
- ▶ Las fuentes  $\vec{s}(t)$  son las señales del cerebro
- ▶ **ventaja:** sin modelo, no hay que conocer la función de actividad para el análisis


## Señal



## Artefacto: parpadear



## Artefacto: latidos



ICA espacial:

$$\vec{x}(\vec{r}) = \mathbf{A}\vec{s}(\vec{r})$$

- ▶ La segregación funcional del cerebro corresponde a la independencia estadístico espacial
- ▶ Las mezclas  $\vec{x}(\vec{r})$  son las imágenes fMRI
- ▶ Las fuentes  $\vec{s}(\vec{r})$  son los mapas de activación
- ▶ La evaluación temporal de la activación está en las columnas de la matriz de mezcla  $\mathbf{A}$
- ▶ **ventaja:** sin modelo, no hay que conocer la función de actividad para el análisis




ICA espacial:

$$\vec{x}(\vec{r}) = \mathbf{A}\vec{s}(\vec{r})$$

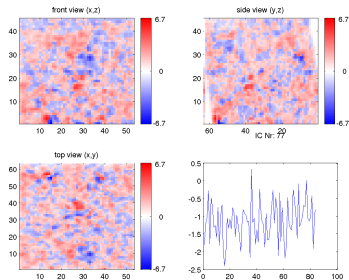
- ▶ La segregación funcional del cerebro corresponde a la independencia estadístico espacial
- ▶ Las mezclas  $\vec{x}(\vec{r})$  son las imágenes fMRI
- ▶ Las fuentes  $\vec{s}(\vec{r})$  son los mapas de activación
- ▶ La evaluación temporal de la activación está en las columnas de la matriz de mezcla  $\mathbf{A}$
- ▶ **ventaja:** sin modelo, no hay que conocer la función de actividad para el análisis

# Ejemplos de componentes



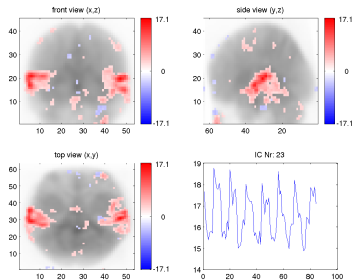
artefactos

# Ejemplos de componentes



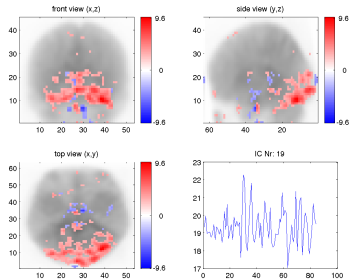
ruído

# Ejemplos de componentes



tarea

# Ejemplos de componentes



no-tarea

# Ejemplo: Un experimento de percepción de palabras

## Organización:

- ▶ 4 personas escuchan palabras transformadas
- ▶ 4 clases, basado en el número de las bandas de frecuencia (FB1–FB4)
- ▶ sólo la clase FB4 se puede interpretar como palabras
- ▶ Tarea: Presionar un botón si se ha entendido la palabra

## Análisis clásico mediante GLM:

- ▶ sólo 1 de las 4 personas tenía una activación que estaba correlacionada con la función de actividad (corteza auditiva y áreas motoras suplementarias)
- ▶ no se encontró ninguna activación en las regiones para la percepción de la palabra

# Ejemplo: Un experimento de percepción de palabras

## Organización:


- ▶ 4 personas escuchan palabras transformadas
- ▶ 4 clases, basado en el número de las bandas de frecuencia (FB1–FB4)
- ▶ sólo la clase FB4 se puede interpretar como palabras
- ▶ Tarea: Presionar un botón si se ha entendido la palabra

## Análisis clásico mediante GLM:

- ▶ sólo 1 de las 4 personas tenía una activación que estaba correlacionada con la función de actividad (corteza auditiva y áreas motoras suplementarias)
- ▶ no se encontró ninguna activación en las regiones para la percepción de la palabra

# ICA espacial mediante FastICA


- ▶ Varias componentes con actividad en la corteza auditiva (todos)
- ▶ Varias componentes con actividad en las áreas motoras sup. (todos)
- ▶ Componentes relacionadas a una red de detección de palabras (3 personas)
- ▶ Componentes relacionadas a una red de decisión (3 personas)






# ICA espacial mediante FastICA

- ▶ Varias componentes con actividad en la corteza auditiva (todos)
- ▶ Varias componentes con actividad en las áreas motoras sup. (todos)
- ▶ Componentes relacionadas a una red de detección de palabras (3 personas)
- ▶ Componentes relacionadas a una red de decisión (3 personas)




# ICA espacial mediante FastICA

- ▶ Varias componentes con actividad en la corteza auditiva (todos)
- ▶ Varias componentes con actividad en las áreas motoras sup. (todos)
- ▶ Componentes relacionadas a una red de detección de palabras (3 personas)
- ▶ Componentes relacionadas a una red de decisión (3 personas)




# ICA espacial mediante FastICA

- ▶ Varias componentes con actividad en la corteza auditiva (todos)
- ▶ Varias componentes con actividad en las áreas motoras sup. (todos)
- ▶ Componentes relacionadas a una red de detección de palabras (3 personas)
- ▶ Componentes relacionadas a una red de decisión (3 personas)



# ICA espacial mediante FastICA



corr = 0.36

## Conclusión:

- ▶ ICA funciona bien con datos de fMRI
  - ▶ ICA es una clase de análisis “sin-modelo” para fMRI
  - ▶ ICA presenta mejores resultados que GLM
- ⇒ ICA puede ser una herramienta poderosa en la investigación del cerebro

## Problemas:

- ▶ Estabilidad de ICA?
- ▶ La necesidad de “post-procesamiento” manual (entre 50 y 400 componentes por sesión)
- ▶ Alta demanda computacional

## Conclusión:

- ▶ ICA funciona bien con datos de fMRI
  - ▶ ICA es una clase de análisis “sin-modelo” para fMRI
  - ▶ ICA presenta mejores resultados que GLM
- ⇒ ICA puede ser una herramienta poderosa en la investigación del cerebro

## Problemas:

- ▶ Estabilidad de ICA?
- ▶ La necesidad de “post-procesamiento” manual (entre 50 y 400 componentes por sesión)
- ▶ Alta demanda computacional

## Conclusión:

- ▶ ICA funciona bien con datos de fMRI
  - ▶ ICA es una clase de análisis “sin-modelo” para fMRI
  - ▶ ICA presenta mejores resultados que GLM
- ⇒ ICA puede ser una herramienta poderosa en la investigación del cerebro

## Problemas:

- ▶ **Estabilidad de ICA?**
- ▶ La necesidad de “post-procesamiento” manual (entre 50 y 400 componentes por sesión)
- ▶ Alta demanda computacional

# Problema: Estabilidad de ICA

Muchos de los algoritmos ICA son estocásticos:

- ▶ Resultados dependientes de las condiciones iniciales
- ▶ Hay que probar la estabilidad de las componentes

Prueba de estabilidad:

- ▶ inicialización aleatoria del algoritmo
- ▶ “Re-muestreo” de los datos: Jackknife, Bootstrapping, ...
- ▶ comparación de ejecuciones múltiples del algoritmo ICA con diferentes opciones



# Problema: Estabilidad de ICA

Muchos de los algoritmos ICA son estocásticos:


- ▶ Resultados dependientes de las condiciones iniciales
- ▶ Hay que probar la estabilidad de las componentes

Prueba de estabilidad:

- ▶ inicialización aleatoria del algoritmo
- ▶ “Re-muestreo” de los datos: Jackknife, Bootstrapping, ...
- ▶ comparación de ejecuciones múltiples del algoritmo ICA con diferentes opciones


No se puede ignorar el ruido en fMRI:

$$\vec{x}(\vec{r}) = \mathbf{A}\vec{s}(\vec{r}) + \vec{n}(\vec{r})$$



No se puede ignorar el ruido en fMRI:


$$\vec{x}(\vec{r}) = \mathbf{A}\vec{s}(\vec{r}) + \vec{n}(\vec{r})$$



Indicador simple: Varianza

$$\text{Var}(\vec{y}) = E [(\vec{y} - m_{\vec{y}})^2] = \sigma^2$$


límite del umbral:  $0 \times$  varianza



Indicador simple: Varianza

$$\text{Var}(\vec{y}) = E [(\vec{y} - m_{\vec{y}})^2] = \sigma^2$$

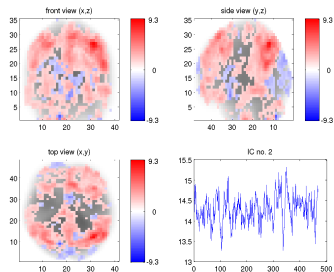
límite del umbral:  $1 \times$  varianza



Indicador simple: Varianza

$$\text{Var}(\vec{y}) = E [(\vec{y} - m_{\vec{y}})^2] = \sigma^2$$


límite del umbral:  $2 \times$  varianza



Indicador simple: Varianza

$$\text{Var}(\vec{y}) = E [(\vec{y} - m_{\vec{y}})^2] = \sigma^2$$


límite del umbral:  $3 \times$  varianza



Indicador simple: Varianza

$$\text{Var}(\vec{y}) = E [(\vec{y} - m_{\vec{y}})^2] = \sigma^2$$

límite del umbral:  $4 \times$  varianza






Indicador simple: Varianza

$$\text{Var}(\vec{y}) = E [(\vec{y} - m_{\vec{y}})^2] = \sigma^2$$


límite del umbral:  $5 \times$  varianza



Indicador simple: Varianza

$$\text{Var}(\vec{y}) = E [(\vec{y} - m_{\vec{y}})^2] = \sigma^2$$


límite del umbral:  $6 \times$  varianza



Indicador simple: Varianza

$$\text{Var}(\vec{y}) = E [(\vec{y} - m_{\vec{y}})^2] = \sigma^2$$


límite del umbral:  $7 \times$  varianza



Indicador simple: Varianza

$$\text{Var}(\vec{y}) = E [(\vec{y} - m_{\vec{y}})^2] = \sigma^2$$


límite del umbral:  $8 \times$  varianza



Indicador simple: Varianza

$$\text{Var}(\vec{y}) = E [(\vec{y} - m_{\vec{y}})^2] = \sigma^2$$


límite del umbral:  $9 \times$  varianza



Indicador simple: Varianza



$$\text{Var}(\vec{y}) = E [(\vec{y} - m_{\vec{y}})^2] = \sigma^2$$

límite del umbral:  $10\times$  varianza



Comparación de similares y diferentes componentes utilizando la correlación

$$C(\vec{y}_i, \vec{y}_j) = E((\vec{y}_i - \vec{m}_{\vec{y}_i})(\vec{y}_j - \vec{m}_{\vec{y}_j})^T) / (|\vec{y}_i| |\vec{y}_j|)$$



## Conclusión:

- ▶ ICA funciona bien con datos de fMRI
  - ▶ ICA es una clase de análisis “sin-modelo” para fMRI
  - ▶ ICA presenta mejores resultados que GLM
- ⇒ ICA puede ser una herramienta poderosa en la investigación del cerebro

## Problemas:

- ▶ Estabilidad de ICA
- ▶ **La necesidad de “post-procesamiento” manual (entre 50 y 400 componentes por sesión)**
- ▶ Alta demanda computacional



Cuáles son los objetivos de la investigación del cerebro mediante fMRI?

- ▶ Encontrar un punto de actividad en el cerebro
- ▶ Encontrar una red de puntos de actividad en el cerebro
  - ▶ actividades en redes tienen evaluaciones temporales similares
  - ▶ ICA en fMRI: las columnas de la matriz de mezcla son las evaluaciones temporales de los mapas de activación espacial

⇒ Clustering basado en la similitud de las columnas de la matriz de mezclas

Cuáles son los objetivos de la investigación del cerebro mediante fMRI?

- ▶ Encontrar un punto de actividad en el cerebro
- ▶ Encontrar una red de puntos de actividad en el cerebro
  - ▶ actividades en redes tienen evaluaciones temporales similares
  - ▶ ICA en fMRI: las columnas de la matriz de mezcla son las evaluaciones temporales de los mapas de activación espacial

⇒ Clustering basado en la similitud de las columnas de la matriz de mezclas

Cuáles son los objetivos de la investigación del cerebro mediante fMRI?

- ▶ Encontrar un punto de actividad en el cerebro
- ▶ Encontrar una red de puntos de actividad en el cerebro
  - ▶ actividades en redes tienen evaluaciones temporales similares
  - ▶ ICA en fMRI: las columnas de la matriz de mezcla son las evaluaciones temporales de los mapas de activación espacial

⇒ Clustering basado en la similitud de las columnas de la matriz de mezclas

Cuáles son los objetivos de la investigación del cerebro mediante fMRI?

- ▶ Encontrar un punto de actividad en el cerebro
- ▶ Encontrar una red de puntos de actividad en el cerebro
  - ▶ actividades en redes tienen evaluaciones temporales similares
  - ▶ ICA en fMRI: las columnas de la matriz de mezcla son las evaluaciones temporales de los mapas de activación espacial

⇒ Clustering basado en la similitud de las columnas de la matriz de mezclas

$$\vec{x}(t) = A\vec{s}(t) \quad \begin{array}{l} \text{fuentes } s_l(t), l = 1, \dots, m \\ \text{mezclas } x_j(t), j = 1, \dots, n \end{array}$$

$m > n$ : ICA sobre-completo  $\rightarrow$  difícil (FastGeo, sparse CA, ...)  
 $m = n$ : ICA completo  $\rightarrow$  normal (muchos algoritmos)  
 $m < n$ : ICA sub-completo  $\rightarrow$  utiliza PCA para  $m = n$

idea común: siempre trata de obtener todas las fuentes originales  $\vec{s}(t)$

$$\vec{x}(t) = A\vec{s}(t) \quad \begin{array}{l} \text{fuentes } s_l(t), l = 1, \dots, m \\ \text{mezclas } x_j(t), j = 1, \dots, n \end{array}$$

- $m > n$ : ICA sobre-completo  $\rightarrow$  difícil (FastGeo, sparse CA, ...)
- $m = n$ : ICA completo  $\rightarrow$  normal (muchos algoritmos)
- $m < n$ : ICA sub-completo  $\rightarrow$  utiliza PCA para  $m = n$

idea común: siempre trata de obtener todas las fuentes originales  $\vec{s}(t)$

$$\vec{x}(t) = A\vec{s}(t) \quad \begin{array}{l} \text{fuentes } s_l(t), l = 1, \dots, m \\ \text{mezclas } x_j(t), j = 1, \dots, n \end{array}$$

- $m > n$ : ICA sobre-completo  $\rightarrow$  difícil (FastGeo, sparse CA, ...)
- $m = n$ : ICA completo  $\rightarrow$  normal (muchos algoritmos)
- $m < n$ : ICA sub-completo  $\rightarrow$  utiliza PCA para  $m = n$


**idea común:** siempre trata de obtener todas las fuentes originales  $\vec{s}(t)$

¿Qué sucede si intencionalmente son extraídas menos fuentes  $m$ ?




¿Qué sucede si intencionalmente son extraídas menos fuentes  $m$ ?

3 mezclas y 3 fuentes




¿Qué sucede si intencionalmente son extraídas menos fuentes  $m$ ?

ICA completo




¿Qué sucede si intencionalmente son extraídas menos fuentes  $m$ ?



reducción de dimensiones usando  
Análisis de Componentes Principales (PCA)

→ las fuentes cercanas en el espacio de mezcla son agrupadas formando nuevos prototipos


¿Qué sucede si intencionalmente son extraídas menos fuentes  $m$ ?




reducción de dimensiones usando pocas mezclas

→ las fuentes cercanas en el espacio de mezcla son agrupadas formando nuevos prototipos


64 puntos de fuentes en el grid forman patrones en las mezclas:




$$\vec{x}(t_1) =$$




64 puntos de fuentes en el grid forman patrones en las mezclas:




$$\vec{x}(t_2) =$$




64 puntos de fuentes en el grid forman patrones en las mezclas:




$$\vec{x}(t_3) =$$



64 puntos de fuentes en el grid forman patrones en las mezclas:




$$\vec{x}(t_4) =$$






64 puntos de fuentes en el grid forman patrones en las mezclas:





$$\vec{x}(t_5) =$$




# Juego de datos


64 puntos de fuentes en el grid forman patrones en las mezclas:




64 puntos de fuentes en el grid forman patrones en las mezclas:




$$\vec{x}(t_7) =$$




64 puntos de fuentes en el grid forman patrones en las mezclas:




$$\vec{x}(t_8) =$$




64 puntos de fuentes en el grid forman patrones en las mezclas:




$$\vec{x}(t_9) =$$



64 puntos de fuentes en el grid forman patrones en las mezclas:




$$\vec{x}(t_{10}) =$$




# ICA incompleto con PCA supera k-means clustering

Agrupamiento basado en las columnas de la matriz de mezcla usando PCA:




*k-means*: no puede agrupar las fuentes correctas que forman los grupos A y C.



*inICA con PCA*: agrupa correctamente de 3 a 30 componentes.

# ICA incompleto dejando datos por fuera

Agrupamiento dejando afuera mezclas:



*Error!*

- ▶ No. de fuentes  $>$  No. de mezclas (sobre-completo)
- ▶ es necesario realizar un “denoising” con PCA




# Agrupando Partes de Objetos

- ▶ ICA incompleto; agrupamiento basado en la presencia de las fuentes en las mezclas
- ▶ en una secuencia de imágenes son agrupadas las partes de un objeto que aparecen en las mismas posiciones




- ▶ por ejemplo comenzar con los filtros para los bordes verticales



# Agrupando Partes de Objetos

- uso de inICA en los bordes filtrados de la secuencia:



## ICA incompleto:


- ▶ agrupamientos basados en semejanzas de las columnas de la matriz de mezcla
- ▶ en fMRI: las columnas de la matriz de mezcla son los cursos de tiempo de los mapas espaciales de la activación
- ▶ las actividades en las redes tienen cursos similares de tiempo

⇒ inICA podría permitir encontrar redes en el cerebro muy fácilmente.

ICA incompleto:

- ▶ agrupamientos basados en semejanzas de las columnas de la matriz de mezcla
- ▶ en fMRI: las columnas de la matriz de mezcla son los cursos de tiempo de los mapas espaciales de la activación
- ▶ las actividades en las redes tienen cursos similares de tiempo

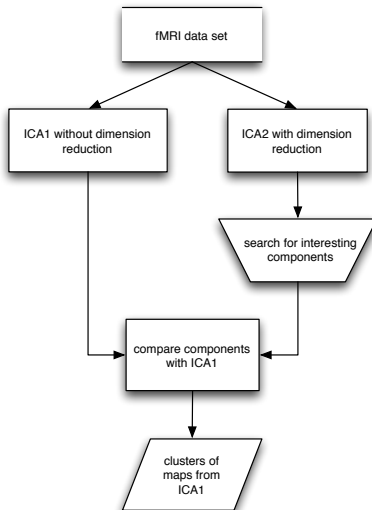
⇒ inICA podría permitir encontrar redes en el cerebro muy fácilmente.



Idea:

- ▶ ICA incompleto de bajas dimensiones para encontrar redes interesantes de la actividad cerebral
- ▶ ICA (completo) de altas dimensiones para encontrar todas las componentes que crean estas redes


# ICA incompleto: Diagrama de flujo



# Paso 1: ICA incompleto

## Ejemplo WCST

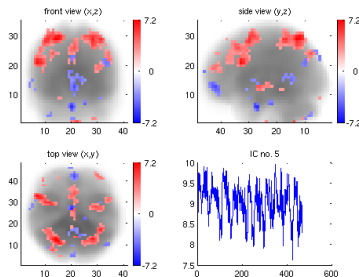
Reducción a 10 dimensiones usando PCA:



# Paso 1: ICA incompleto

## Ejemplo WCST

Reducción a 20 dimensiones usando PCA:

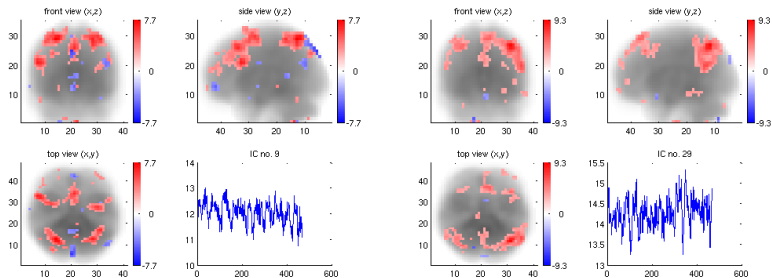




# Paso 1: ICA incompleto

## Ejemplo WCST

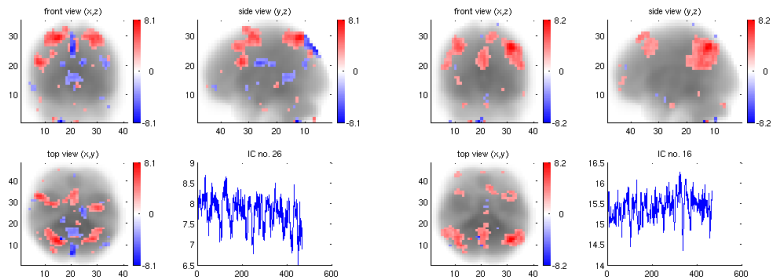
Reducción a 40 dimensiones usando PCA:



# Paso 1: ICA incompleto

## Ejemplo WCST





Reducción a 50 dimensiones usando PCA:



# Paso 2: ICA completo


## Ejemplo WCST

Búsqueda automatizada en el resultado de un ICA completo para las componentes que crean la red demostrada:



# ICA completo e incompleto

- ▶ Usando el resultado del ICA incompleto los resultados del ICA completo se pueden evaluar automáticamente
- ▶ El curso de tiempo de una IC interesante en inICA, corresponde a la suma de los cursos de tiempo de las ICs en ICA completo



## Conclusion:

- ▶ ICA trabaja bien en datos fMRI
  - ▶ ICA es una clase de análisis “sin modelo” para fMRI
  - ▶ ICA puede superar GLM
- ⇒ ICA puede ser una herramienta poderosa en la investigación del cerebro

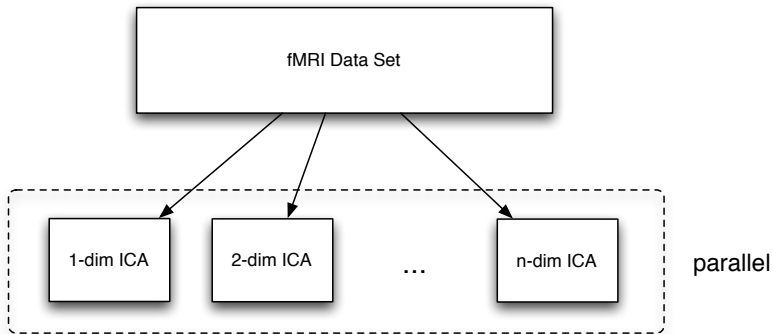
## Problemas:

- ▶ Estabilidad ICA
- ▶ La necesidad de post-procesamiento manual (entre 100 y 400 componentes por sesión)
- ▶ **Alta demanda computacional**

Haciéndolo paralelamente:

- ▶ el flujo del trabajo de inICA contiene muchos módulos independientes
- ▶ la prueba de confiabilidad de diversos funcionamientos de inICA es independiente
- ▶ la prueba de confiabilidad en sí mismo es generalmente independiente

La paralelización es directa y eficiente.




Haciéndolo paralelamente:

- ▶ el flujo del trabajo de inICA contiene muchos módulos independientes
- ▶ la prueba de confiabilidad de diversos funcionamientos de inICA es independiente
- ▶ la prueba de confiabilidad en sí misma es generalmente independiente

La paralelización es directa y eficiente.






Haciéndolo paralelamente:

- ▶ el flujo del trabajo de inICA contiene muchos módulos independientes
- ▶ la prueba de confiabilidad de diversos funcionamientos de inICA es independiente
- ▶ la prueba de confiabilidad en sí mismo es generalmente independiente

La paralelización es directa y eficiente.

# inICA Paralelo y Pruebas de Estabilidad



Haciéndolo paralelamente:

- ▶ el flujo del trabajo de inICA contiene muchos módulos independientes
- ▶ la prueba de confiabilidad de diversos funcionamientos de inICA es independiente
- ▶ la prueba de confiabilidad en sí mismo es generalmente independiente

La paralelización es directa y eficiente.

Haciéndolo paralelamente:

- ▶ el flujo del trabajo de inICA contiene muchos módulos independientes
- ▶ la prueba de confiabilidad de diversos funcionamientos de inICA es independiente
- ▶ la prueba de confiabilidad en sí mismo es generalmente independiente

**La paralelización es directa y eficiente.**

Actualmente existen muchos estándares en la programación paralela, ej. MPI (Message Passing Interface), PVM (Parallel Virtual Maching):

- ▶ optimizado para (muchos) mensajes cortos
- ▶ inadecuado para el transporte de grandes datos
- ▶ necesita instalaciones especiales de software

fMRI: pocos mensajes; pero grandes sistemas de datos

Idea:

- ▶ utilizar el sistema de archivos de redes para el transporte de datos fMRI
- ▶ utilizar el sistema de archivos de redes para los mensajes

Actualmente existen muchos estándares en la programación paralela, ej. MPI (Message Passing Interface), PVM (Parallel Virtual Maching):

- ▶ optimizado para (muchos) mensajes cortos
- ▶ inadecuado para el transporte de grandes datos
- ▶ necesita instalaciones especiales de software

fMRI: pocos mensajes; pero grandes sistemas de datos

Idea:

- ▶ utilizar el sistema de archivos de redes para el transporte de datos fMRI
- ▶ utilizar el sistema de archivos de redes para los mensajes

Actualmente existen muchos estándares en la programación paralela, ej. MPI (Message Passing Interface), PVM (Parallel Virtual Maching):


- ▶ optimizado para (muchos) mensajes cortos
- ▶ inadecuado para el transporte de grandes datos
- ▶ necesita instalaciones especiales de software

fMRI: pocos mensajes; pero grandes sistemas de datos

Idea:

- ▶ utilizar el sistema de archivos de redes para el transporte de datos fMRI
- ▶ utilizar el sistema de archivos de redes para los mensajes





Proceso del servidor:

- ▶ creación de trabajos (Matlab/Octave scripts)
- ▶ análisis de resultados
- ▶ interfaz de usuario

Proceso del cliente:

- ▶ espera para los trabajos
- ▶ ejecuta trabajos

Importante para el investigador:

- ▶ influencia de la componente en el sistema de datos  
→ clasificación basada en la influencia
- ▶ relación con otras componentes  
→ demostrar las conexiones
- ▶ confiabilidad de la componente  
→ demostrar la confiabilidad

Gráfico de salida como archivo SVG

Importante para el investigador:

- ▶ influencia de la componente en el sistema de datos  
→ clasificación basada en la influencia
- ▶ relación con otras componentes  
→ demostrar las conexiones
- ▶ confiabilidad de la componente  
→ demostrar la confiabilidad

Gráfico de salida como archivo SVG

Importante para el investigador:

- ▶ influencia de la componente en el sistema de datos  
→ clasificación basada en la influencia
- ▶ relación con otras componentes  
→ demostrar las conexiones
- ▶ confiabilidad de la componente  
→ demostrar la confiabilidad


Gráfico de salida como archivo SVG

Importante para el investigador:

- ▶ influencia de la componente en el sistema de datos  
→ clasificación basada en la influencia
- ▶ relación con otras componentes  
→ demostrar las conexiones
- ▶ confiabilidad de la componente  
→ demostrar la confiabilidad

Gráfico de salida como archivo SVG

# Ejemplo



- ▶ Ejemplo de WCS
- ▶ el color da la fuerza de la conexión y la confiabilidad
- ▶ permite investigar los cambios en las componentes

# Ejemplo





- ▶ ICA funciona bien con datos fMRI
- ▶ ICA es una clase de análisis “sin modelo” para fMRI
- ▶ ICA incompleto puede ser utilizado como método de agrupamiento
- ▶ la paralelización es directa
- ▶ permite el análisis exploratorio de los datos

⇒ ICA puede ser una herramienta poderosa para futuras investigaciones del cerebro

# Conclusiones y Perspectivas

- ▶ ICA funciona bien con datos fMRI
- ▶ ICA es una clase de análisis “sin modelo” para fMRI
- ▶ ICA incompleto puede ser utilizado como método de agrupamiento
- ▶ la paralelización es directa
- ▶ permite el análisis exploratorio de los datos

⇒ ICA puede ser una herramienta poderosa para futuras investigaciones del cerebro

# Conclusiones y Perspectivas

- ▶ ICA funciona bien con datos fMRI
- ▶ ICA es una clase de análisis “sin modelo” para fMRI
- ▶ ICA incompleto puede ser utilizado como método de agrupamiento
- ▶ la paralelización es directa
- ▶ permite el análisis exploratorio de los datos

⇒ ICA puede ser una herramienta poderosa para futuras investigaciones del cerebro

- ▶ ICA funciona bien con datos fMRI
- ▶ ICA es una clase de análisis “sin modelo” para fMRI
- ▶ ICA incompleto puede ser utilizado como método de agrupamiento
- ▶ la paralelización es directa
- ▶ permite el análisis exploratorio de los datos

⇒ ICA puede ser una herramienta poderosa para futuras investigaciones del cerebro

# Conclusiones y Perspectivas

- ▶ ICA funciona bien con datos fMRI
- ▶ ICA es una clase de análisis “sin modelo” para fMRI
- ▶ ICA incompleto puede ser utilizado como método de agrupamiento
- ▶ la paralelización es directa
- ▶ permite el análisis exploratorio de los datos

⇒ ICA puede ser una herramienta poderosa para futuras investigaciones del cerebro

- ▶ ICA funciona bien con datos fMRI
- ▶ ICA es una clase de análisis “sin modelo” para fMRI
- ▶ ICA incompleto puede ser utilizado como método de agrupamiento
- ▶ la paralelización es directa
- ▶ permite el análisis exploratorio de los datos

⇒ ICA puede ser una herramienta poderosa para futuras investigaciones del cerebro

# Gracias por su atención.

<http://ingokeck.de/es/>